Chicago Road Risk

Big Data y modelado predictivo geoespacial para priorizar intervenciones de seguridad vial en la Ciudad de Chicago

Especialización en Big Data

Sustentación de avance · 2026

Deivid Julian Cardenas Melo · Dillan Alexander Cardenas Melo · Camilo Escandón Romero
Universidad CESMAG · San Juan de Pasto, Colombia

1 Introducción

Chicago publica cada día los reportes policiales de sus accidentes de tránsito, junto con los permisos de obra y los aforos vehiculares. Son datos abiertos, pero están separados en cinco fuentes, tienen errores de ubicación y nadie los cruza entre sí.

Construimos una plataforma que los integra, los limpia y los relaciona en el espacio para responder una pregunta práctica: dónde conviene intervenir primero. Todo con herramientas de código abierto y contenedores Docker.

2 Definición del problema

Entre enero de 2023 y octubre de 2026 la ciudad registró más de 418 mil siniestros. Los graves son pocos y están dispersos, y el presupuesto para reformar vías alcanza para pocos tramos.

418.170	445	1,6 %
siniestros analizados	personas fallecidas	son graves o fatales

Pregunta de decisión: *¿cómo usar los resultados de un modelo predictivo para priorizar las intervenciones preventivas en los tramos viales de mayor riesgo?*

3 Objetivos

General. Desarrollar una plataforma analítica geoespacial que clasifique y anticipe los tramos viales de mayor riesgo en Chicago.

OE1	Diseñar una base de datos geoespacial en PostgreSQL + PostGIS.
OE2	Automatizar el ETL con limpieza y cruce espacial a 250 m.
OE3	Implementar modelos que clasifiquen tramos por nivel de riesgo.
OE4	Visualizar los resultados en una aplicación web cartográfica.

4 Metodología

API SODA (5 datasets abiertos) → Bronze (Parquet crudo) → Silver (PostgreSQL + PostGIS) → Gold (DuckDB (OLAP)) → Modelos (Logística · RF · XGBoost) → Web (FastAPI + MapLibre)

Datos y calidad

Descargamos 2,6 millones de registros desde 2023 con paginación y reintentos. Validamos tipos, quitamos duplicados y apartamos en cuarentena los puntos fuera de Chicago (4.456 sin coordenadas válidas). Eliminamos datos personales de las víctimas.

Integración espacial

Cada siniestro se cruzó con la estación de aforo más cercana (vecino más próximo) y con las obras con cierre de calzada vigentes a menos de 250 m. Las distancias se miden en la proyección EPSG:3435 de Illinois, en metros reales.

Modelado y validación

La unidad de predicción es la cuadra. Con 12 meses de historia se anticipa su riesgo de los 12 siguientes. Entrenamos con 2023 → 2024 y evaluamos prediciendo 2025, más validación cruzada por bloques espaciales de 2 km.

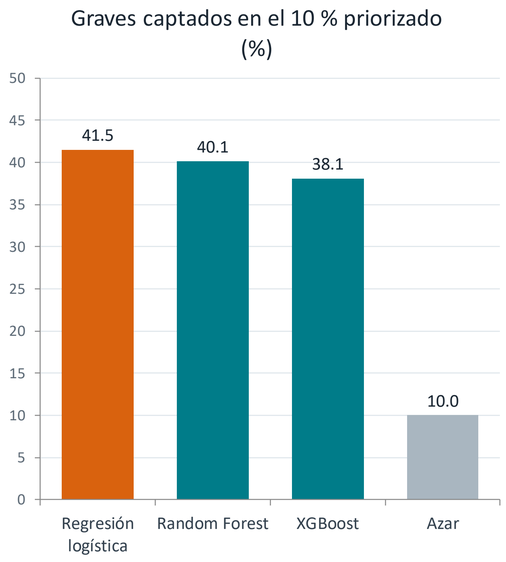
5 Resultados

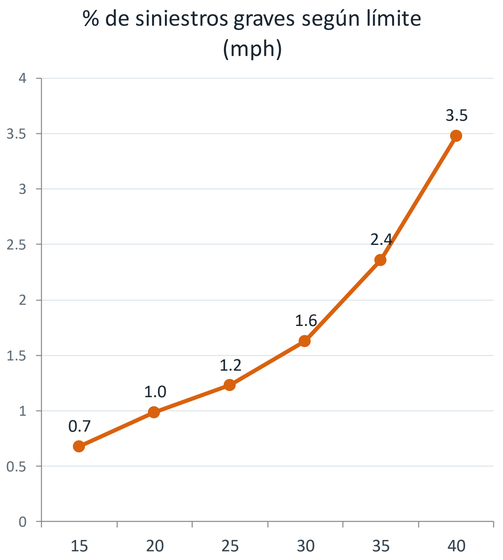
41,5 %

de los siniestros graves de 2025 ocurrió en el 10 % de cuadras que el modelo priorizó con datos de 2024

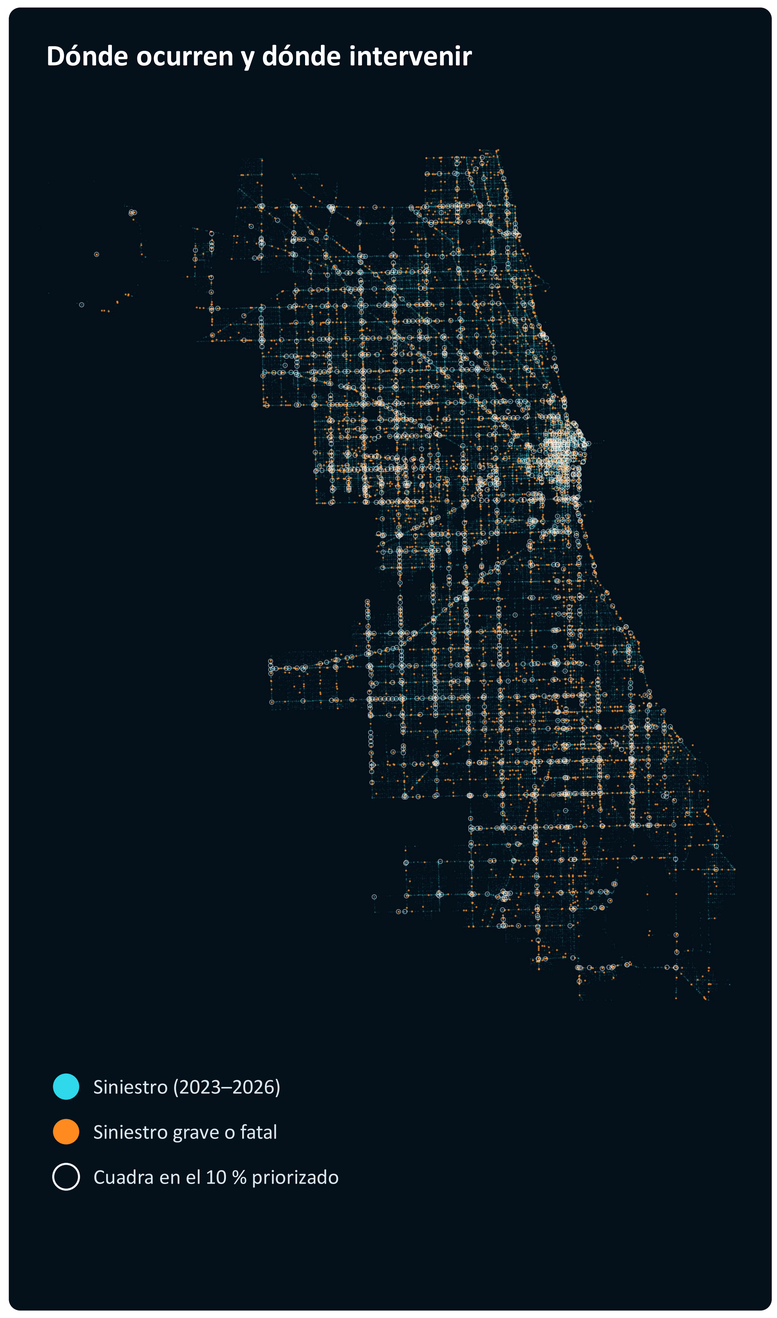
4,2 veces más que elegir cuadras al azar

AUC 0,80 · recall 0,62 · 21.416 cuadras





98,9 %	0 %	9×	19 s
registros procesados con éxito	duplicados tras la limpieza	más graves los atropellos	para levantar la plataforma



6 Conclusiones

- Interviniendo el 10 % de cuadras que señala el modelo se atiende el lugar donde ocurrió el 41,5 % de los siniestros graves del año siguiente.
- Un modelo simple y explicable (regresión logística) prioriza tan bien como Random Forest y XGBoost.
- Peatones, ciclistas, motociclistas y velocidad explican la gravedad: bajar de 30 a 25 mph en las cuadras priorizadas es la medida con más respaldo.
- La precisión en casos graves (0,07) no alcanzó la meta: con 1,6 % de casos, conviene medir por captura y lift.

7 Referentes

City of Chicago. (2026). Traffic Crashes – Crashes, Vehicles y People [Conjuntos de datos]. Chicago Data Portal. https://data.cityofchicago.org

City of Chicago. (2026). Transportation Department Permits [Conjunto de datos]. Chicago Data Portal.

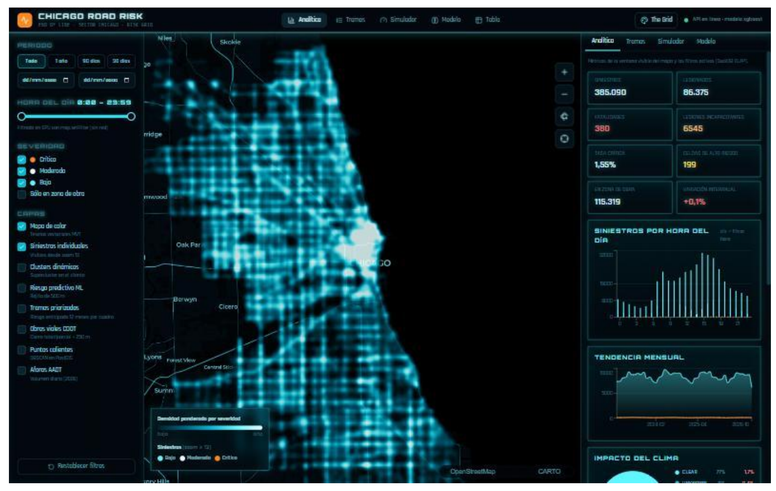
Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of KDD ’16, 785–794.

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters. Proceedings of KDD-96, 226–231.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. JMLR, 12, 2825–2830.

La aplicación web



Mapa WebGL con los 418 mil siniestros en teselas vectoriales, filtros por hora y severidad, lista de cuadras prioritarias y simulador de riesgo.

Código y documentación: github.com/DeividCardenas/proyecto_final_espe