UNIVERSIDAD CESMAG
NIT: 800.109.387-7
VIGILADA MINEDUCACIÓN

Chicago Road Risk

Big Data y modelado predictivo geoespacial para priorizar intervenciones de seguridad vial en la Ciudad de Chicago

Especialización en Big Data

Sustentación de avance · 2026

Deivid Julian Cardenas Melo · Dillan Alexander Cardenas Melo · Camilo Escandón Romero
Universidad CESMAG · San Juan de Pasto, Colombia

1 Introducción

Chicago publica a diario los reportes de sus accidentes de tránsito, los permisos de obra y los aforos vehiculares. Son datos abiertos, pero viven en fuentes separadas, con errores de ubicación y sin cruzarse entre sí. Los integramos para responder una pregunta práctica: dónde conviene intervenir primero.

Fuente (Chicago Data Portal)	Registros
Siniestros	418.170
Vehículos	853.359
Personas (anonimizadas)	919.337
Permisos de obra CDOT	257.506
Aforos vehiculares (AADT)	1.279

Periodo: enero 2023 – octubre 2026 · 2,4 millones de registros depurados

2 Definición del problema

En casi cuatro años la ciudad acumuló más de 418 mil siniestros. Los graves son pocos y están dispersos, y el presupuesto para reformar vías solo alcanza para algunos tramos.

418.170 siniestros

445 fallecidos

1,6 % graves o fatales

Pregunta de decisión

¿Cómo usar los resultados de un modelo predictivo para priorizar las intervenciones preventivas en los tramos viales de mayor riesgo?

3 Objetivos

General. Desarrollar una plataforma analítica que identifique y clasifique los tramos viales de mayor riesgo en Chicago, como apoyo a la toma de decisiones en seguridad vial.

- **OE1** Construir una base de datos geoespacial integrada. + del 95 % de registros válidos indexados
- **OE2** Automatizar la integración y depuración de los datos. + del 95 % procesado con éxito
- **OE3** Clasificar los segmentos viales por nivel de riesgo. AUC ≥ 0,70 y recall ≥ 0,60
- **OE4** Visualizar los resultados en una aplicación web. Despliegue < 2 min, respuesta < 2 s

4 Metodología

API SODA (5 fuentes abiertas) → **Bronze** (Parquet crudo) → **Silver** (PostgreSQL + PostGIS) → **Gold** (DuckDB (OLAP)) → **Modelos** (Logística · RF · XGBoost) → **Aplicación web** (FastAPI + React + MapLibre)

Datos y calidad

Descarga paginada desde la API con reintentos. Validación de tipos, deduplicación y cuarentena de puntos fuera de Chicago. Sin datos personales de las víctimas.

Integración espacial

Cada siniestro se une a la estación de aforo más cercana y a las obras con cierre de calzada vigentes a menos de 250 m, medidos en metros reales (EPSG:3435).

Modelado

La unidad es la cuadra. Con 12 meses de historia se anticipa su riesgo de los 12 siguientes: Bajo, Medio o Alto. Se comparan tres algoritmos.

Validación

Fuera de tiempo: se entrena con 2023 → 2024 y se evalúa prediciendo 2025 contra lo que realmente ocurrió. Además, validación cruzada por bloques de 2 km.

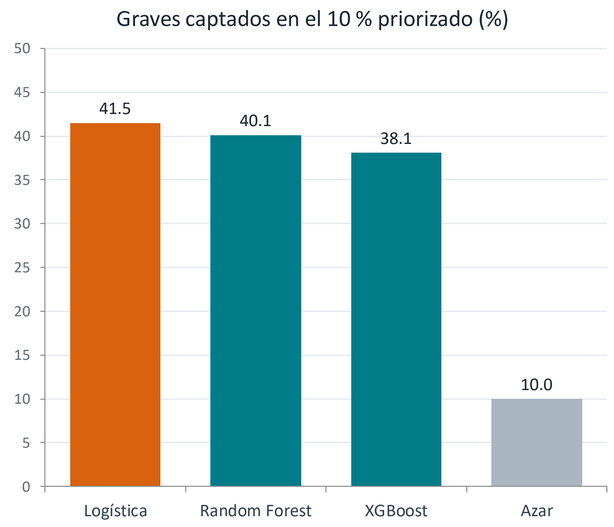
5 Resultados

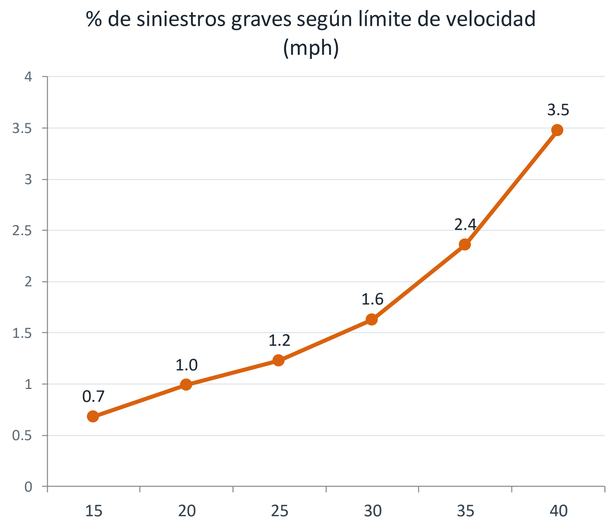
41,5 %

de los siniestros graves de 2025 ocurrió en el 10 % de cuadras que el modelo priorizó con datos de 2024

4,2 veces más que elegir cuadras al azar

21.416 cuadras evaluadas · AUC 0,80





Comparación en 2025

Modelo	AUC	Recall	Top 10 %
Logística ★	0,796	0,62	41,5 %
Random Forest	0,800	0,34	40,1 %
XGBoost	0,794	0,48	38,1 %

★ elegido: capta más graves en el top 10 % y es el más fácil de explicar. Validación espacial estable: variación del AUC menor al 0,5 %.

98,9 % registros procesados

0 % duplicados

0,708 AUC modelo por siniestro

19 s despliegue con Docker

0,76 s respuesta media (50 usuarios)

6 Hallazgos para la ciudad

Peatones — 9×

El 14,4 % de los atropellos termina en lesión grave o muerte, frente al 1,6 % promedio.

Velocidad — 0,7 → 3,5 %

La proporción de siniestros graves crece sin excepción de 15 a 40 mph.

Corredores — 5

Western, Pulaski, Cicero, Halsted y Ashland concentran más siniestros graves.

Obras — ≈

Las obras con cierre no aumentan la gravedad: 1,51 % con obra frente a 1,60 % sin ella.

7 Conclusiones

- Interviniendo el 10 % de cuadras que señala el modelo se cubre el 41,5 % de los siniestros graves del año siguiente.
- Un modelo simple y explicable (regresión logística) prioriza tan bien como Random Forest y XGBoost.
- Bajar de 30 a 25 mph y proteger los cruces peatonales en las cuadras priorizadas es la medida con más respaldo.
- La precisión en casos graves (0,07) no alcanzó la meta: con 1,6 % de casos, conviene evaluar por captura y lift.

8 Referentes

City of Chicago. (2026). Traffic Crashes: Crashes, Vehicles y People [Datos]. Chicago Data Portal. https://data.cityofchicago.org

City of Chicago. (2026). Transportation Department Permits [Datos]. Chicago Data Portal.

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proc. KDD '16, 785–794.

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters. Proc. KDD-96, 226–231.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. JMLR, 12, 2825–2830.

Mapa impreso y demostración en vivo en el stand · github.com/DeividCardenas/proyecto_final_espe